

exp-fips203-mlkem-pke-decrypt-k2

FIPS 203 Alg.15 ML-KEM-512 PKE Decrypt 实现方案

ascendc 工程 (ML-KEM-512 W4a / E15)

2026-07-27

摘要

本文档描述 `examples/incubating/ml-kem/ml-kem-512/exp-fips203-mlkem-pke-decrypt-k2/` 在 Atlas A2 / Ascend910B4 上以 AscendC 实现 FIPS 203 Algorithm 15, 即 ML-KEM-512 ($k=2$) PKE Decrypt。

参数锁定: 参数卡与 `ascendc-tests/ml-kem/ml-kem-512/pass-fix-f203-alg15-pke-decrypt-device-k2/STATUS.md`。生产 I/O: input/ 为 `dk_pke.bin` (768B)、`c.bin` (768B) 与静态 LUT; output/ 仅 `m.bin` (32B)。计划 AI Core 数: 1 launch; `f203_decrypt_device_fused` 为 MIX blockDim=1 (S-1)。**禁止:** 写入 `stable-512`; 从 `frozen/` 抄码; 用 k3/k4 字节长或假 poly 替代 k2 几何。

目录

1	工程边界	2
1.1	禁止项	2
2	数学语义 (Alg.15, $k=2$, $n=256$, $q=3329$)	2
2.1	输入输出	2
2.2	阶段公式	2
3	AscendC 实现规划	3
3.1	Launch 与 AI Core 规模	3
3.2	GM 几何	3
4	AscendC API 表	3
4.1	评估过但未采用	4
5	数学步骤覆盖率	5
6	验证计划	5
7	产出物	5

1 工程边界

来源	用途
ascendc-tests/ml-kem/ml-kem-512/pass-fix-f203- alg15-pke-decrypt-device-k2/ examples/incubating/ml-kem/ml-kem-768/exp-fips203-mlkem-pke-decrypt-k3/ library/shared/ CANN / tikicpulib / CAModel	活跃 D15 k2 行为基线；可复制后自包含适配 活跃 k3 incubating 结构参考；仅 retarget 到 k2 统一整数压缩/解压等共享库 编译与运行环境

1.1 禁止项

- 禁止从 frozen/ 拿源码、customspec 或路线。
- 禁止将 u' 、 v' 、 $\hat{s}$ 、 $\hat{u}$ 、 w 等中间态作为默认 I/O 落盘。
- 禁止读写第 3/4 个假 poly；NTT/INTT 仅 AIV0=poly0、AIV1=poly1。
- 禁止新建或写入 stable-512。

2 数学语义 (Alg.15, $k = 2$, $n = 256$, $q = 3329$)

2.1 输入输出

张量 / 文件	契约
input/dk_pke.bin	768B; $\hat{s}$ 的 ByteEncode ₁₂ , 即 $2 \times 384B$
input/c.bin	768B; $c = c_1 \ c_2$, 其中 $c_1 = 640B$ ($d_u = 10$, 2 poly), $c_2 = 128B$ ($d_v = 4$, 1 poly)
input/lut_even_stacked.bin	NTT/INTT Stage2 LUT
lut_odd_stacked.bin	
output/m.bin	32B, ByteEncode ₁ (Compress ₁ (w))

2.2 阶段公式

1. 行 1-2: 拆分 $c_1 = c[0 : 640]$, $c_2 = c[640 : 768]$ 。
2. 行 3: $u' \leftarrow \text{Decompress}_{10}(\text{ByteDecode}_{10}(c_1))$, 得到 2 个 poly。

3. 行 4: $v' \leftarrow \text{Decompress}_4(\text{ByteDecode}_4(c_2))$, 得到 1 个 poly。
4. 行 5: $\hat{s} \leftarrow \text{ByteDecode}_{12}(\text{dk_pke})$, 得到 2 个 NTT 域 poly。
5. 行 6: $\hat{u} \leftarrow \text{NTT}(u')$; $\hat{w} \leftarrow \sum_{j=0}^1 \text{MultiplyNTTs}(\hat{s}[j], \hat{u}[j])$; 再对 $\hat{w}$ pad 到 k2 前缀后执行 INTT, 得到 w_t 。
6. 行 7: $w = (v' - w_t) \bmod q$, $m = \text{ByteEncode}_1(\text{Compress}_1(w))$ 。

尾段方向锁定: Decrypt 行 7 是 $\text{ByteEncode}_1(\text{Compress}_1(w))$, 不是 Encrypt 的 $\text{Decompress}_1(\text{ByteDecode}_1(m))$ 。

3 AscendC 实现规划

3.1 Launch 与 AI Core 规模

Launch	核类型 / blockDim	数据划分与理由
1 fused	MIX, blockDim=1	S-1: AIV0 负责 unpack、 $\hat{s} \cdot \hat{u}$ 与尾 pack 关键串行段; NTT/INTT AIV0=poly0、AIV1=poly1。继承 D15 k2 GATE 4/8 与 softSyncGm。

3.2 GM 几何

对象	锁定几何
u'	[2,256] int32; c1 d10 unpack + Decompress10
v'	[1,256] int32; c2 d4 unpack + Decompress4
$\hat{s}$	[2,256] int32; dk_pke ByteDecode12
$\hat{u}$ NTT	真 polyvec2; AIV 1+1, 禁止读写假 poly
$\hat{w}$ / INTT	$\hat{w}$ 写入 k2 前缀, 后续 INTT 只消费第 0 个时域 poly
Tail pack	Compress1 产 256 bit; ByteEncode1 LSB-first pack 为 32B

4 AscendC API 表

本实现不引入 E15 独有的新 AscendC API。

API 名	分类 / 文档	Atlas A2	本用例 dtype	备注
GetBlockIdx / GetSubBlockIdx	系统变量 / 资源	√	标量索引	区分 AIV 分片与 MIX 子核

GlobalTensor / LocalTensor	基础结构	√	uint8/int8/int32/UB 张量契约须与本 spec 几何一致
DataCopy	Memory 数据搬运	√	uint8/int8/int32 连续块搬运; 32B 对齐约束
Duplicate	Memory 矢量计算	√	uint8/int32 UB 清零、pad 与 tail buffer 初始化
PipeBarrier	Pipe 同步	√	— MTE/Vector/Cube 阶段交界显式同步
CrossCoreSetFlag / CrossCoreWaitFlag	MIX 同步	√	— AIV/AIC 通过 GM 交接; CPU 过不能删
Mmad / Fixpipe	矩阵计算	√	int8*int8->int32 8x8 MMAD; 硬件 M 对齐垫不表示假 poly
ShiftRight	矢量算术	√	int32 limb 拆分、Barrett 与 ByteEncode 辅助右移
Muls / Add / Sub	矢量算术	√	int32/int16 limb、模加减、压缩/编码辅助
Cast	类型转换	√ (受限)	int32/int16/int8 遵守 A28 Cast 链; 不得假设 int32->int8 单跳
Gather	矢量搬运/选择	√	int32 仅允许非 NTT S1-S3 段; NTT 三段内禁用
GetValue / SetValue	LocalTensor 标量访问	√	uint8/int32 仅用于 pack 尾部等标量缺口

4.1 评估过但未采用

API / 路线	不采用原因
真向量 ByteEncode1 bit pack	d=1 跨字节 bit 流, 已有标量 pack 更简单且 D15 已验
Gather 用于 NTT S1-S3	NTT 定稿禁止

读写假第 3/4 poly

S-1 / 禁零垫

5 数学步骤覆盖率

数学步骤	实现方式 / API	覆盖	缺口说明
ByteDecode/Decompress d10/d4	标量 unpack + 统一整 数向量 Decompress	部分向量	bit unpack 标量 缺口沿用 D15
ByteDecode12($\hat{s}$)	标量 unpack	部分向量	与 D15 基线一致
NTT(u') 与 $\hat{s} \cdot \hat{u}$	MIX + Mmad + Alg.11	100% 设备	NTT 内无 Gather
INTT($\hat{w}$)	MIX Stage3 merge	100% 设备	pad 到 k2 前缀
Compress1 + ByteEncode1	向量 Barrett + 标量 bit pack	部分向量	ByteEncode1 标 量缺口沿用 D15

6 验证计划

```
cd examples/incubating/ml-kem/ml-kem-512/exp-fips203-mlkem-pke-decrypt-k2
bash run.sh -r cpu -v Ascend910B4
SIM_DIRECT=1 bash run.sh -r sim -v Ascend910B4
```

期望: m.bin 为 32B, 与 golden 对拍 PASS; 用例根无 stray dump。

7 产出物

- exp-fips203-mlkem-pke-decrypt-k2-实现方案-customspec.tex
- exp-fips203-mlkem-pke-decrypt-k2-实现方案-customspec.pdf
- 后续实现文件须与本 customspec 同目录自包含, 且自研 Python/C/AscendC 写详细中文注释。