

exp-fips203-mlkem-kem-decaps-k3

FIPS 203 Alg.21 ML-KEM-768 KEM Decaps 实现方案

ascendc 工程 (ML-KEM-768 W4b / E21)

2026-07-26

摘要

本文档描述 `examples/incubating/ml-kem/ml-kem-768/exp-fips203-mlkem-kem-decaps-k3/`: 在 **Atlas A2 / Ascend910B4** 上以 AscendC 实现 FIPS 203 **Algorithm 21**, 即 ML-KEM-768 ($k=3$) **KEM Decaps**。

参数锁定: 几何、I/O 与 launch 全部锁定到 `docs/specs/fips203-mlkem768-parameter-card.md` §3.3 D21: `dk_kem=2400B`, `c=1088B`, 输出 `K=32B`; SIM/生产默认 `decaps_1session`, T19i 形态 **3 launch**。**行为基线**: 活跃探针 `ascendc-tests/ml-kem/ml-kem-768/pass-fix-f203-alg21-kem-decaps-device-k3/`。**组成**: Phase-D 复用 E15/D15 k3 Decrypt fused; Phase-E 复用 E14/D14 k3 Encrypt 几何, 并在设备侧完成 $G(m' || h)$ 、再加密、密文比较与 FO 选路。**计划 AI Core 数**: Phase-D 为 MIX blockDim=1; Phase-E prep 为 AIV_ONLY blockDim=2; Phase-E compute+pack+FO 为 MIX blockDim=1 (1 AIC + 2 AIV)。**禁止**: 创建 `examples/stable/ml-kem/ml-kem-768/`; 从任何 `frozen/` 目录复制、改写或移植源码; 沿用 k4 的 `dk=3168/c=1568, du=11/dv=5` 或 `pad-to=4/8` 几何。

目录

1 工程边界	2
1.1 禁止项	2
2 数学语义 (Alg.21 → Alg.18)	2
3 AscendC 实现规划	3
3.1 GM 几何	3
3.2 同步与流水	4
4 AscendC API 表	4
5 数学步骤覆盖率	5
6 验证计划	6
7 产出物	6

1 工程边界

来源	用途
ascendc-tests/ml-kem/ml-kem-768/pass-fix-f203-alg21-kem-decaps-device-k3/	活跃 D21 k3 行为基线；可复制后自包含适配到本 exp，最终不得保留对探针目录的编译期 include/import
examples/incubating/ml-kem/ml-kem-768/exp-fips203-mlkem-pke-decrypt-k3/	活跃 E15 incubating PKE Decrypt；提供已自包含的 k3 Alg.15 主体
examples/incubating/ml-kem/ml-kem-768/exp-fips203-mlkem-pke-encrypt-k3/	活跃 E14 incubating PKE Encrypt；提供已自包含的 k3 Alg.14 主体
examples/incubating/ml-kem/ml-kem-1024/exp-fips203-mlkem-kem-decaps-k4/	活跃 k4 incubating Decaps 结构参考；仅用于目录组织与状态口径，不带入 k4 字节长或几何
library/shared/	SHA3/SHAKE、统一整数压缩、公共设备侧头文件等共享库
CANN / tikicpulib / CAModel	编译、CPU 孪生与 SIM 运行环境

1.1 禁止项

- 禁止从 ascendc-tests/frozen/ 或 examples/frozen/ 拿源码、customspec 或路线。
- 禁止把 m' 、 K' 、 r' 、 c' 、 h 、 z 等中间态作为默认 I/O 落盘；debug dump 只能由显式开关启用。
- 禁止 Host 预填 r' 、Host memcmp 或 Host SHAKE256 选 K 冒充生产 FO； G 与 FO 必须在设备侧完成。
- 禁止为 G 或 FO 新增与 Encrypt/Decrypt 无关的产品化独立 launch；默认路径须保持 D21 T19i 三段结构。
- 禁止将本 E21 delivery 默认改为 decaps_2session；2-session 仅作为调试覆盖或 E21ct 默认。

2 数学语义 (Alg.21 $\rightarrow$ Alg.18)

张量 / 文件

契约

input/dk_kem.bin	2400B, 展开为 $dk_{PKE}(1152) ek(1184) h(32) z(32)$
input/c.bin	1088B, $c = c_1 c_2$, 其中 $c_1 = 960B$ ($d_u = 10$, 3 poly), $c_2 = 128B$ ($d_v = 4$, 1 poly)
input/lut_even_stacked.bin	Decrynt/Encrypt NTT/INTT Stage2 LUT; 由本目录
lut_odd_stacked.bin	golden 脚本生成; 不是用户可见交付输入
output/K.bin	32B; 合法路径为 K' , 拒绝路径为 $J(z c)$

$$\begin{aligned}
m' &\leftarrow \text{K-PKE.Decrypt}(dk_{PKE}, c) \\
(K' || r') &\leftarrow G(m' || h) = \text{SHA3-512}(m' || h) \\
c' &\leftarrow \text{K-PKE.Encrypt}(ek, m', r') \\
K &\leftarrow \begin{cases} K' & \text{若 } c = c' \\ J(z || c) = \text{SHAKE256}(z || c, 32) & \text{若 } c \neq c' \end{cases}
\end{aligned}$$

行 1-4 只做 dk_kem 指针切片, 不另开 launch; 行 8-12 的比较与 J 选路在设备 FO 中完成。

3 AscendC 实现规划

Launch	核类型 / blockDim	数据划分与理由
Phase-D	MIX, blockDim=1	继承 E15/D15: Decode12、unpack c 、 NTT/Inner/INTT、 Compress1+ByteEncode1, 输出 m' 到 GM workspace。选择 1 个 AI Core 是参数 卡 §3.3 D21 对 D15 fused 的锁定继承。
Phase-E prep	AIV_ONLY, blockDim=2	block0 先执行 $G(m' h)$ 产生 $K' r'$; 随后 继承 E14/D14 prep: $\hat{A}$ 共 9 poly 按 5+4 分片, $y e_1 e_2$ 共 7 poly 由 r' 采样。
Phase-E compute+FO	MIX, blockDim=1	复用 E14/D14 compute; SIM 在本地 118_119 覆盖核尾部 pack 出 c' 后, 同核 执行 KemDecFo 写 K.bin。

3.1 GM 几何

对象	锁定几何
dk_kem	2400B; 偏移: $dk_{pke}[0, 1152)$, $ek[1152, 2336)$, $h[2336, 2368)$, $z[2368, 2400)$
c / c'	1088B; $d_u = 10, d_v = 4$, $c_1=960B$, $c_2=128B$

$\hat{A}$	[9,256] int32; 9 个真实 poly, 禁止 pad 到 16
re	[7,256] int32; y[0..2] e1[0..2] e2[0], 随机性来自设备 r'
Phase-E INTT	真 polyvec4: S0 [8,256] int8, Stage2 mat_c [32,128] int32; 硬件 M 对齐垫不表示假 poly
Kprime / Kout	各 32B; Kprime 为 workspace, Kout 为唯一 D2H 输出

3.2 同步与流水

Phase-D 与 Phase-E 之间由 Host launch 顺序保证 GM 可见性; SIM 默认在同一 ACL session 内连续执行, 保持 decaps_1session。Phase-E prep 内 G 写出 $K' || r'$ 后, PRF/CBD 必须读取完整 r' ; 沿用 D21 已验顺序与 barrier。Phase-E compute 内部沿用 E14/D14 同步: AIV 与 AIC 通过 CrossCore flag 交接平面 Stage1/Stage2/Stage3 GM; AIV 双分片 pack 完成后使用 SyncAll 汇合, 再由固定 AIV 执行 FO。CPU 仅作为逻辑孪生; SIM 是同步与搬运验收门槛。

4 AscendC API 表

本实现不引入 E21 独有的新 AscendC 矢量/矩阵 API; KEM 头尾使用 shared Keccak Sha3OneShot/Shake256。下表 API 均已有索引记录, 使用约束按 library/documents/CANN-AscendC 算子开发接口参考-查阅索引.md 执行。

API 名	分类 / 文档	Atlas A2	本用例 dtype	备注
GetBlockIdx / GetSubBlockIdx	系统变量 / 资源	√	标量索引	区分 AIV 分片与 MIX 子核; KEM 头尾仅固定 block/subblock 执行
GlobalTensor / LocalTensor	基础结构	√	uint8/int8/int32	3D/UB 张量契约必须与本 spec 几何一致
DataCopy	Memory 数据搬运	√	uint8/int8/int32	连续块搬运; 长度与地址遵守 32B 对齐约束
Duplicate	Memory 矢量计算	√	uint8/int32	用于 UB 清零、pad 与 tail buffer 初始化
PipeBarrier	Pipe 同步	√	—	MTE/Vector/Cube 阶段交界显式同步

CrossCoreSetFlag / CrossCoreWaitFlag	MIX 同步	√	—	AIV/AIC 通过 GM 交接时使用；CPU 过不能删
SyncAll	硬同步	√	—	双 AIV pack 完成后汇合，再由 AIV0 执行 FO
Mmad / Fixpipe	矩阵计算	√	int8*int8->int32	NTT/INTT Stage2 MMAD；k3 真 batch 几何
ShiftRight	矢量算术	√	int32	limb 拆分、Barrett 压缩与 ByteEncode 辅助右移
Muls / Add / Sub	矢量算术	√	int32/int16	limb、模加减、压缩/编码辅助
Cast	类型转换	√（受限）	int32/int16/half/int8	遵守 A2 Cast 链约束；不得假设存在 int32->int8 单跳
Gather	矢量搬运/选择	√	int32	仅允许在 Alg.11 / ByteEncode 等非 NTT S1-S3 段按既有路径使用；NTT 三段内禁用
GetValue / SetValue	LocalTensor 标量访问	√	uint8/int32	仅用于 pack 与 KEM 头尾标量缺口；不得把 Compares bit 包当逐 lane 布尔

5 数学步骤覆盖率

数学步骤	实现方式 / API	覆盖	缺口说明
切分 dk_kem	Host 传整段 GM, kernel 指针偏移	100% 设备	不另开 launch, 不落盘中间态
$m' = \text{Decrypt}$	E15/D15 fused	100% 设备	真 k3、du/dv=10/4

$G(m' h)$	shared Keccak SHA3-512	100% 设备	K' 与 r' 均在设 备 workspace
$\text{Encrypt}(ek, m', r')$	E14/D14 prep+compute	100% 设备	Â[9]、re[7]、 INTT batch4; 无零垫
$c \stackrel{?}{=} c'$ 与 FO	本地 KemDecFo + SHAKE256 J	100% 设备	SIM 嵌入 118_119 尾; CPU 用 pack_fo

6 验证计划

```
cd examples/incubating/ml-kem/ml-kem-768/exp-fips203-mlkem-kem-decaps-k3
bash run.sh -r cpu -v Ascend910B4
SIM_DIRECT=1 bash run.sh -r sim -v Ascend910B4
```

期望: K.bin 为 32B, 合法路径与 golden 对拍 PASS; SIM 默认 decaps_1session, Total tick 登记到 qa/active_sim_regress_summary.md, 并检查用例根目录无 stray core*.dump、profile_*log*.toml。
可选拒绝对照:

```
KEM_DECAPS_REJECT=1 bash run.sh -r cpu -v Ascend910B4
KEM_DECAPS_REJECT=1 SIM_DIRECT=1 bash run.sh -r sim -v Ascend910B4
```

7 产出物

- exp-fips203-mlkem-kem-decaps-k3-实现方案-customspec.tex
- exp-fips203-mlkem-kem-decaps-k3-实现方案-customspec.pdf
- 后续实现文件须与本 customspec 同目录自包含, 且自研 Python/C/AscendC 写详细中文注释。