

exp-fips203-compress-unified-int-vec-k4

FIPS 203 统一整数 Compress_d 向量实现方案

ascendc 工程

2026-07-10

摘要

本文档描述 `examples/incubating/exp-fips203-compress-unified-int-vec-k4/` 在 Ascend910B / AIV-only 单 launch 上实现 FIPS 203 §4.2.1 **Compress_d** 的统一整数舍入路径。公式锁定为 $C = \lfloor 2^{37}/q \rfloor = 41285357$, $\text{Compress}_d(u) = (C \cdot u + 2^{36-d}) \gg (37 - d)$; 设备侧用 **int32 limb 宽乘** ($C = 629 \cdot 2^{16} + 63213$) 避免 $C \cdot u$ 的 int32 环绕。数学推导见 `docs/notes/F203-Compress-Decompress-统一整数舍入技术总结.md`。

1 数学语义

1.1 输入输出

- 输入 `poly.bin`: $N = 256$ 个 int32, 各 $u \in [0, q)$, $q = 3329$ 。
- 输出 `comp.bin`: N 个 int32, 值为 $\text{Compress}_d(u)$ 再 mask 到 d bit (与 FIPS 一致)。
- 档位 $d \in \{1, 4, 5, 10, 11\}$, 由编译期 `F203_UNIFIED_ROUND_D` 选择。

1.2 统一常数

$$C = \left\lfloor \frac{2^{37}}{q} \right\rfloor = 41285357 = 629 \cdot 2^{16} + 63213$$

按 d 派生 bias 与 acc shift (见 `library/shared/f203_unified_round/f203_unified_round_params.hpp`)。

2 设备实现

2.1 核函数

`compress_unified_int_custom (KERNEL_TYPE_AIV_ONLY, blockDim=1): GM → UB → 共享头 poly_compress_unified_local → GM。`

2.2 向量路径 (默认)

`COMPRESS_UNIFIED_INT_VEC=1:`

1. `Muls(lo, in, C0), Muls(hi, in, C1);`
2. 进位安全合并 `carry (ShiftRight + mask_low_bits + Adds/Add);`
3. `ShiftRight(out, hi+carry, acc_shift);`
4. `mask_low_bits(out, d)。`

UB 须 4 路独立 `int32` (lo/hi/carry/tmp), 禁止与 out 别名。

2.3 标量对照

`COMPRESS_UNIFIED_INT_VEC=0`: 逐 lane `int64` 计算 $(C \cdot u + \text{bias}) \gg k$, 用于 SIM tick 基准。

3 Golden 与验收

- Golden: `compress_unified_int_ref.c`(Host gcc 动态库, 与 kernel 同 `F203_UNIFIED_ROUND_D`)。
- 命令: `bash run.sh -r cpu -v Ascend910B4;F203_UNIFIED_ROUND_D=11 SIM_DIRECT=1 bash run.sh -r sim -v Ascend910B4。`
- 验收: `output/comp.bin` 与 `output/golden_comp.bin` 逐字节一致 (`verify_result.py`)。
- 生产集成: stable Encrypt tail (`d=5/11`) 已内联同公式; 本 exp 为单算子隔离探针。

4 性能参考 (SIM, 2026-07-10)

向量 limb 路径各档 tick $\approx 3.38\text{k}-3.42\text{k}$; 标量 `int64 lane` $\approx 10.7\text{k}$; 提升约 **3.15–3.18**×。